大语言模型课程 Final Project 评分标准

评分总则

- 项目默认形式：2-4 人一组，微调一个大语言模型。
- 只要模型微调成功（代码可运行、模型产生有效输出），即可获得 **30 分**，加上平时分大概率保证总分及格。
- 满分：**100 分**（微调项目），**120 分**（创新项目、难度极大的微调项目）。
- 所有项目必须提交：报告（**每人一份**，含小组成员贡献说明）、代码、以及汇报 PPT。
- Presentation 要求：逻辑清晰，对每个处理步骤及技术名词背后的含义要有清晰解释。允许项目在展示时尚未完全完成，但需给出明确的未来预期与可行性分析。

1 微调项目基础要求与及格项（30 分）

- 成功加载预训练模型（如 LLaMA、Qwen 等）。
- 准备一个用于微调的数据集（不低于 500 条）。
- 完成训练循环，模型 Loss 下降，并能生成与任务相关的合理文本。
- 提交可复现的代码与简要说明。

达到以上条件即获得 30 分。

2 区分度评分（0-60 分）

以下五项总分 60 分，每项独立打分，档位清晰。

2.1 数据多样性（0-12 分）

分数	标准
0-4 分	使用单一来源、格式简单的数据（如只有 QA 对），且未做任何清洗或增强。
5-8 分	数据来自至少 2 种不同来源（如指令数据 + 对话数据），做了基本清洗与去重。
9-12 分	数据包含 3 种以上类型（如文本分类、摘要、代码生成），或采集了真实场景下的多源数据，或进行了高质量的数据增强，或收集并清洗了自己的数据。

2.2 数据采集与处理难度（0-12 分）

分数	标准
0-4 分	使用完全公开的标准数据集（如 Kaggle 数据），仅做格式转换。
5-8 分	整合多个公开数据集，或对公开数据进行较复杂的处理（如去污、过滤、格式统一）。
9-12 分	自行爬取/收集数据，并完成清洗、标注或构建格式。需说明采集渠道与难度，例如：学术论文摘要抓取、客服对话脱敏、多语言平行语料构建等。

2.3 模型多样性（0-10 分）

分数	标准
0-3 分	只使用一个模型（如 LLaMA-7B），且是常见配置。
4-7 分	尝试至少 2 种不同架构或规模的模型（如 7B 与 13B，或 LLaMA 与 Qwen），并报告基础对比结果。
8-10 分	比较 3 个及以上有显著差异的模型（不同系列、不同参数规模），并进行深入的性能与效率对比分析。需包含量化、推理速度等实践对比。

2.4 超参数选取与调优（0-12 分）

分数	标准
0-4 分	使用单一超参数，无任何调优尝试。
5-8 分	对学习率、batch size、epochs 进行了简单网格搜索或实验，并报告了 Loss 曲线。
9-12 分	系统性地调优超参数（包括 LoRA rank/alpha、学习率调度、优化器选择），讨论了过拟合/欠拟合现象，并给出最优选择的依据。使用了类似权重衰减、warmup 等技术。

2.5 比较与消融实验（0-14 分）

分数	标准
0-5 分	只展示最终模型的结果，无任何比较。
6-10 分	至少进行了一组有效对比：比如不同数据规模对比、有无指令微调对比、或不同超参数配置对比。提供了定量指标（如 BLEU, ROUGE, 准确率）。
11-14 分	进行多维度比较（数据规模 + 模型选择 + 超参数），并能分析出哪些因素最重要。同时可能包含基座模型与微调模型的人工评估。实验设计正交、结论可靠。

3 Presentation 与逻辑清晰度（0-10 分）

分数	标准
0-3 分	展示混乱，术语解释不清，没有体现分工与对每个步骤的理解。
4-7 分	逻辑基本清晰，能解释主要技术名词（如 LoRA、QLoRA、SFT、tokenization），分工明确，结果展示合理。
8-10 分	逻辑非常清晰，能深入解释每个技术选择背后的原理（为何选该数据集、为何用该超参数）。对未完成部分给出合理的预期与风险分析。听众提问能从容回答，展示出深刻理解。

额外加分：难度极大的优秀项目（100-120 分）

要达到 100 分以上，必须在上述多项中获得高分且整体难度极大。典型示例：

- 在对话/推理等具有挑战性的任务上明显超越现有开源模型（在公开 benchmark 上提升显著）。
- 使用 RLHF 或 DPO 等复杂对齐技术，并完成高质量奖励模型训练。
- 在低资源语言、垂直专业领域（医疗、法律、代码生成）构建了高质量数据集并取得真实可用效果。
- 系统性地比较了全量微调、LoRA、QLoRA 在不同硬件约束下的 trade-off。
- 项目产出可部署的演示应用，且代码文档完善。

评分时，教师根据项目的创新性、工作量与技术难度酌情给分。

4 创新项目通道（非微调，满分 120 分）

允许学生不做标准微调，而是提出与本课程相关的创新项目，例如：

- 设计新的模型架构或注意力机制改进。
- 大模型评估方法研究或新基准测试构建。
- 大模型可解释性工具、数据污染检测、越狱攻击与防御。
- 针对特定应用的提示工程框架或自动提示优化系统。
- Agent、RAG 系统的新颖设计，并进行系统级评估。

评分规则：

- **基础可行性（40 分）**：项目有明确的 motivation 和预期实现路径，完成核心原型或仿真实验，报告清晰。
- **新颖性与原创性（0-30 分）**：根据 idea 的新颖程度打分，越新颖越高。完全重复已有开源方案得 0-10 分；有显著改进或新应用场景得 11-20 分；全新问题或方法得 21-30 分。
- **技术难度与工作量（0-30 分）**：涵盖数据、代码、实验量。对比微调项目，需要论证更复杂的实现或分析。

- **展示与理解深度（0-20 分）**：与微调项目 Presentation 标准类似，但要求对创新点有更深入的论证和局限性分析。
- 最终得分 = 基础可行性 + 新颖性 + 技术难度 + 展示深度，满分 120 分。
- 创新项目总分超过 100 分即相当于微调项目中的优秀档次，加号无额外上限（按 120 满分记录成绩）。

小组分工与额外激励

- 每个小组必须提交**贡献声明**，明确每位成员在数据采集、模型训练、超参数调优、评估、代码编写、报告撰写、展示中的具体任务。
- 从事难度较大的数据采集与清洗、多模型训练对比、调优大量实验的成员，教师在最终分数评定时有倾斜。

最后提醒：评分标准旨在鼓励深度探索和清晰表达，而非单纯堆砌实验。祝同学们取得优异成果。